

Análisis de Factores Demográficos, Clínicos y de Estilo de Vida en la
Predicción del Riesgo de Diabetes



Universidad del Rosario

Asignatura: Análisis Estadístico de Datos

Docente: Luz Adriana Pineda

Integrantes:

Samuel Santiago Arandia Barragán

Juan David Castañeda Betancourt

Juan Felipe Rojas Manjarres

2026

Introducción

La diabetes es una enfermedad crónica de alta prevalencia cuyo diagnóstico puede requerir múltiples pruebas y tiempo. En este contexto, el presente estudio tiene como propósito optimizar el proceso de diagnóstico mediante el uso de modelos predictivos basados en la base de datos NHANES 2013–2014.

Objetivo Principal

Analizar la relación entre factores demográficos, medidas corporales, variables de actividad física y variables dietarias, con el fin de identificar patrones asociados al riesgo de diabetes y evaluar qué variables o exámenes clínicos permiten su predicción.

Objetivos Específicos

- Analizar la distribución de variables clínicas relevantes, como la hemoglobina glucosilada, la presión arterial y el IMC.
- Aplicar técnicas de probabilidad multivariada para modelar la relación conjunta entre las variables y estimar la probabilidad de presentar diabetes.
- Formular conclusiones a partir de los resultados obtenidos que permitan optimizar la selección de exámenes clínicos, favoreciendo una detección más eficiente de condiciones de riesgo para la predicción de la enfermedad.

Pregunta de Investigación

¿En qué medida variables básicas (demográficas, medidas corporales, actividad física y dieta) permiten orientar

la selección de exámenes clínicos relevantes y a partir de estos estimar la probabilidad de padecer diabetes?

Revisión Bibliográfica

El desarrollo de la diabetes está estrechamente relacionado con factores de estilo de vida como la actividad física, la dieta y el tabaquismo, los cuales influyen significativamente en el riesgo de la enfermedad. La adopción de hábitos saludables en estos aspectos puede reducir la probabilidad de aparición hasta en un 82% [1].

En este sentido, la alimentación desempeña un papel fundamental, ya que dietas con mayor consumo de fibra y menor ingesta de carbohidratos refinados se asocian con un menor riesgo de diabetes, lo que resalta la importancia de incluir variables dietarias en el análisis [2].

Por otra parte, variables clínicas como la hemoglobina glicosilada y los niveles de colesterol son determinantes en la evaluación del riesgo debido a su relación directa con el estado metabólico del individuo [3].

Estos antecedentes respaldan el uso de variables fáciles de recolectar para orientar la selección de exámenes clínicos y optimizar el proceso de diagnóstico de la diabetes.

Marco Metodológico

El presente estudio utiliza la base de datos *National Health and Nutrition Examination Survey (NHANES)* 2013–2014, obtenida de Kaggle y recolectada por los CDC, que incluye información

demográfica, clínica, de laboratorio y de estilo de vida de la población estadounidense.

A partir de la base original (10.175 individuos, 1.829 variables), se realizó un proceso de depuración y selección, obteniendo una matriz final de 16 variables relevantes. La muestra se restringió a individuos mayores de 45 años ($n = 3.174$), con el fin de enfocarse en una población de mayor riesgo de diabetes.

Las variables incluyen datos cuantitativos (edad, IMC, presión arterial, colesterol, hemoglobina glicosilada, insulina, consumo de carbohidratos y fibra) y cualitativos (género, actividad física, tabaquismo, nivel educativo, etnicidad y diagnóstico de diabetes).

Estrategia metodológica

Para dar respuesta a la pregunta de investigación, se propone una metodología basada en técnicas de estadística descriptiva y multivariada, estructurada en las siguientes etapas:

1. Análisis exploratorio de datos

Se realizará un análisis descriptivo univariado y bivariado que permita identificar patrones, distribuciones, valores atípicos y posibles relaciones entre variables explicativas y la variable respuesta (diagnóstico de diabetes).

2. Formulación de hipótesis

Se plantearán hipótesis estadísticas para evaluar la relación entre variables explicativas y la presencia de diabetes. Estas hipótesis serán evaluadas mediante

pruebas como ANOVA, ANCOVA o pruebas no paramétricas según corresponda.

3. Modelación estadística

Se implementarán diferentes técnicas multivariadas para modelar la probabilidad de padecer diabetes:

Regresión logística: para estimar la probabilidad de diabetes en función de variables demográficas, clínicas y de estilo de vida.

Análisis de Componentes Principales (PCA): para reducir la dimensionalidad y detectar estructuras latentes en los datos.

Métodos de clasificación (como árboles de decisión o k-NN): para evaluar la capacidad predictiva de las variables.

4. Interpretación y toma de decisiones

Finalmente, los resultados obtenidos permitirán identificar las variables más relevantes en la predicción de la diabetes, evaluar qué variables pueden sustituir o anticipar la necesidad de exámenes clínicos y proponer estrategias para optimizar el diagnóstico temprano.


Análisis de Variables Categóricas

Tabla 1: Distribución de frecuencias: diagnóstico de diabetes

Categoría	Frecuencia	Porcentaje
Yes	620	19.53%
No	2419	76.21%
Borderline	133	4.19%
Refused	0	0%
Don't know	2	0.06%


La mayoría de los individuos están concentrados en la categoría “No” con un 76.21% , esto significa que la población analizada en su mayoría no cuenta con un diagnóstico de diabetes, sin embargo, el grupo con un diagnóstico no es despreciable con 19.53% y vale la pena hacer un análisis de los factores de riesgo, además la categoría “Borderline” agrupa un 4.19% indicando de presencia de individuos que ya presenta prediabetes, por otro lado las categorías “Refused” y “Don’t know” tienen una participación casi nula por lo que no influyen en el análisis.

Figura 1: Diagrama de barras sport



Existe una clara dominancia de la categoría “No” implicando que la mayoría de los individuos no realiza actividad física, esto es importante dado que el sedentarismo es un factor de riesgo clave para la diabetes.

Figura 2: Treemap distribución de etnicidad




En el gráfico se observa como la muestra presenta una fuerte concentración en la población hispana, lo que sugiere un posible sesgo muestral y una limitación en la generalización de resultados para poblaciones más diversas.

Análisis de Variables Cuantitativas

En el anexo A se observa que las variables presentan distribuciones relativamente centradas, con medias cercanas a sus medianas. No obstante, se observan diferencias importantes en términos de dispersión. Variables como la insulina y el consumo de nutrientes (carbohidratos y fibra) presentan alta variabilidad, lo que sugiere heterogeneidad en los hábitos y condiciones fisiológicas de la población. Por otro lado, la hemoglobina glicosilada destaca por su relevancia clínica, al presentar valores cercanos al umbral diagnóstico de diabetes con una dispersión moderada. Esto indica que, aunque es una variable estable, tiene un alto poder discriminatorio en el diagnóstico.


Figura: 3: gráficos hemoglobina glicosilada



La variable hemoglobina glicosilada presenta una distribución asimétrica con sesgo positivo como se evidencia en el histograma y el gráfico de densidad, los valores centrales se ubican en un rango entre la normalidad y la prediabetes sin

embargo se presentan valores atípicos en la cola superior lo que indica niveles elevados.

Figura: 4: gráficos colesterol



La distribución es relativamente simétrica y los niveles de colesterol se mantienen en niveles medios con ciertos valores atípicos que corresponden a individuos con colesterol alto.


Por otro lado, otras variables importantes como lo son insulina, carbohidratos y fibra comparten patrones de alta asimetría y valores atípicos.

La presencia de asimetría, valores atípicos y que variables clínicas predictivas como la hemoglobina glicosilada y el colesterol se concentren en valores cercanos al límite de lo aceptable puede reducir la precisión de las predicciones y dificultar la identificación temprana de casos de diabetes al no poder discriminar entre individuos con y sin diabetes.

Análisis Descriptivo Bivariado

Con el fin de responder a la pregunta de investigación, para el análisis bivariado se cruzaron características demográficas, de estilo de vida y medidas corporales directamente con el estado clínico del paciente.


Figura: 5: Boxplots de BMI según diagnóstico



El diagrama de cajas muestra que la mediana del IMC es mayor en individuos con diabetes y prediabetes en comparación con el grupo sano. Además, su rango intercuartílico se encuentra desplazado hacia valores asociados con sobrepeso y obesidad.

Aunque existen valores atípicos en todos los grupos, los resultados sugieren una asociación positiva entre el IMC y el riesgo de diabetes.

Figura: 6: Boxplot hemoglobina según diagnóstico con umbral de 6.5%



La distribución de la hemoglobina glicosilada evidencia una clara separación entre grupos. Los individuos sanos presentan valores por debajo del umbral diagnóstico (6.5%), mientras que los pacientes con diabetes lo superan, con mayor dispersión y asimetría positiva.

Esto confirma que la variable es un fuerte predictor clínico del diagnóstico.


Tabla 2: frecuencia doble entrada sport diagnóstico

Diagnóstico de Diabetes			
Sport	Yes	No	Borderline
Yes	40	361	14
No	580	2058	119

El análisis muestra que la prevalencia de diabetes es mayor en individuos sedentarios (aproximadamente 21%) en comparación con aquellos físicamente activos (aproximadamente 9.6%).


Esto indica que el sedentarismo incrementa significativamente el riesgo relativo de diabetes, aunque no es un factor determinante por sí solo.

Figura 7: Densidad de edad por diagnóstico



El gráfico de densidad evalúa la distribución de la edad según el diagnóstico de diabetes. El grupo sano (“No”) concentra su mayor volumen poblacional al inicio del rango y disminuyendo a lo largo de este. En cambio, la curva de los diagnosticados (“Yes”) se desplaza ligeramente a la derecha alcanzando su pico máximo entre los 60 y 65 años. Este desplazamiento sugiere que, dentro del grupo de diabéticos, el envejecimiento actúa como factor de riesgo progresivo.

Figura 8: Matriz de correlaciones



Para complementar el análisis bivariado, se evaluaron las relaciones lineales mediante una matriz de correlación (Anexo B) y sus *scatterplots*. En general, las correlaciones son débiles a moderadas, lo que indica baja multicolinealidad. Se destacan asociaciones esperadas como IMC–peso ($r \approx 0.87$) y carbohidratos–fibra ($r \approx 0.60$).

Variables como edad, presión arterial, colesterol e insulina presentan correlaciones bajas, lo que sugiere relaciones no estrictamente lineales.

La hemoglobina glicosilada muestra bajas correlaciones con la mayoría de variables, pese a su alta capacidad discriminadora. Esto indica que aporta información independiente y que las variables observacionales no capturan completamente el estado clínico, lo cual es consistente con la ausencia de patrones claros en los *scatterplots*.

Estos resultados justifican el uso de modelos como la regresión logística o métodos de clasificación, dado el carácter categórico de la variable respuesta y la ausencia de relaciones lineales claras entre las variables.

Bibliografía

- [1] D. Mozaffarian, A. Kamineni, M. Carnethon, L. Djoussé, K. J. Mukamal y D. S. Siscovick, “Lifestyle Risk Factors and New-Onset Diabetes Mellitus in Older Adults: The Cardiovascular Health Study,” *Archives of Internal Medicine*, vol. 169, no. 8, pp. 798–807, 2009. Disponible en: <https://pmc.ncbi.nlm.nih.gov/articles/PMC2828342/>.
- [2] C. Willi, P. Bodenmann, W. A. Ghali, P. D. Faris y J. Cornuz, “Active smoking and the risk of type 2 diabetes: a systematic review and meta-analysis,” *JAMA*, vol. 298, no. 22, pp. 2654–2664, 2007. Disponible en: <https://pubmed.ncbi.nlm.nih.gov/18544792/>.
- [3] M. Ai et al., “Diabetes risk prediction using clinical and lifestyle variables,” *Nutrients*, vol. 17, no. 7, 1117, 2025. Disponible en: <https://www.mdpi.com/2072-6643/17/7/1117>.

Anexos

Anexo A: Medidas de tendencia central, variabilidad y posición

Variable	Media	Mediana	Varianza	Desv_Estandar	Coef_Variacion	Q1	Q3
Age	62.02	61.00	115.14	10.73	17.30	53.00	70.00
Weight	81.00	78.30	434.92	20.85	25.75	66.60	91.90
Height	166.01	165.70	103.76	10.19	6.14	158.50	173.20
BMI	29.31	28.10	46.97	6.85	23.38	24.70	32.60
Blood_pressure	129.16	126.00	376.93	19.41	15.03	116.00	140.00
Cholesterol	192.99	191.00	1870.49	43.25	22.41	163.00	219.00
Glycohemoglobin	6.01	5.70	1.42	1.19	19.84	5.40	6.10
Insulina	13.80	9.30	568.76	23.85	172.86	5.83	14.88
Carbohydrate	234.71	214.69	13137.48	114.62	48.83	156.31	292.91
Fiber	17.08	14.90	112.70	10.62	62.17	9.70	21.90

Anexo B : Histogramas y correlación

